

第五章 工业大数据

- 5.1 大数据概念
- 5.2 工业大数据及其应用
- 5.3 工业大数据处理过程
- 5.4 工业大数据治理



5.1 大数据概念

购物



5.1 大数据概念

□ 大数据特点

数据量大


大数据中的数据量大,就是指海量数据。由于大数据往往是采取全样分析,因此大数据的“大”首先体现在其**规模和容量**远远超出传统数据的测量尺度。

大数据之“大”还表现在其**采集范围和内容的丰富多变**,能存入数据库的不仅包含各种具有规律性的数据符号,还囊括了各种如图片、视频、声音等非规则的数据。


5.1 大数据概念

□ 大数据特点

数据量大



大型强子对撞机每秒产生PB级的数据



5.1 大数据概念

□ 大数据特点



2^{50} 有多大?

十的幂 (1977)

5.1 大数据概念

□ 大数据特点

数据类型繁多

如今的数据类型早已不是单一的文本形式,除了网络日志、音频、视频、图片、地理位置信息等多类型的数据对数据的处理能力提出了更高的要求,数据来源也越来越多样,不仅产生于组织内部运作的各个环节,也来自组织外部的开放数据。

内部数据



政府数据



企业数据



机构数据

开放数据



- 网站数据
- 各种 App 终端数据
- 大众媒介数据

5.1 大数据概念

□ 大数据特点

数据产生速度快

➤ 数据产生得快

有的数据是爆发式地产生,如欧洲核子研究中心的大型强子对撞机在工作状态下每秒产生 PB级的数据;有的数据是涓涓细流式地产生,但是由于用户众多,短时间内产生的数据量依然非常庞大,如点击流、日志、论坛、博客、发邮件、射频识别数据、GPS(全球定位系统)位置信息。

➤ 数据处理得快

正如水处理系统可以从水库调出水进行处理,也可以处理直接对涌进来的新水流,大数据也有批处理(“静止数据”转换为“正使用数据”)和流处理(“动态数据”转换为“正使用数据”)两种范式,以实现快速的数据处理。

5.1 大数据概念

□ 大数据特点

数据价值密度低

随着互联网以及物联网的广泛应用,信息感知无处不在,但现实世界所产生的数据中,有价值的**数据占比很小**。因此,如何结合业务逻辑并通过强大的机器算法挖掘数据价值,是大数据时代最需要解决的问题。

大数据处理技术在具体的应用方面,可以为国家支柱企业的**数据分析和处理提供技术和平台支持,为企业进行数据分析、处理、挖掘,提取出重要的信息和知识,再转化为有用的模型**。应用到研究、生产、运营和销售过程中。


5.1 大数据概念

□ 大数据技术

数据采集

大数据的应用离不开数据采集。数据采集又称为数据获取,是指利用某些装置,从系统外部采集数据并输入系统内部的一个接口。

数据采集技术是数据处理的必备条件,数据采集除了各类传感设备等硬件软件设施之外,主要涉及数据的 ETL(采集、转换、加载)过程,能对数据进行清洗、过滤、校验、转换等各种预处理,将有效的数据转换为适合的格式和类型。



5.1 大数据概念

□ 大数据技术

数据采集

网络爬虫分类	内容
通用网络爬虫	无特定目标，从起始 URL 出发，遍历整个互联网网页，抓取广泛的公开信息并存储到大型数据库（如搜索引擎索引库）。
聚焦网络爬虫	又称“主题爬虫”，仅抓取与特定主题（如“人工智能论文”“新能源汽车价格”）相关的网页，过滤无关信息，目标性极强。
增量网络爬虫	不重复抓取已抓取过的网页，仅针对“新增或更新的网页”进行抓取，核心是“识别数据变化”。
深层网络爬虫	指常规搜索引擎无法抓取的内容，如需要登录、表单提交才能访问的页面）的数据抓取。

5.1 大数据概念


□ 大数据技术

数据存储

目前常见的大数据存储方式主要有分布式存储、NoSQL数据库和云数据库3种。

➤ 分布式存储

通过网络使用企业中的每台机器上的磁盘空间,并将这些分散的存储资源构成一个虚拟的存储设备,数据分散地存储在企业的各个角落。




5.1 大数据概念

□ 大数据技术

➤ NoSQL数据库

NoSQL, 数据库又叫作**非关系数据库**。NoSQL 数据库一般都具备水平可扩展的特性, 并且可以支持超大规模数据存储, 灵活的数据模型也可以很好地支持 Web 2.0应用, 还具有强大的横向扩展能力。

典型的 NoSQL, 数据库种类有**键值数据库、列族数据库、文档数据库和图形数据库**。



```
管理员: C:\windows\system32\cmd.exe - redis-server redis.windows.conf
D:\Redis-x64-3.2.100 (1)>redis-server redis.windows.conf

Redis 3.2.100 <00000000/0> 64 bit
Running in standalone mode
Port: 6379
PID: 7460

http://redis.io

[7460] 14 Jul 22:34:08.216 # Server started, Redis version 3.2.100
[7460] 14 Jul 22:34:08.216 * The server is now ready to accept connections on port 6379
```


空间换时间

Redis 在 Windows 下的运行界面

5.1 大数据概念

□ 大数据技术

➤ NoSQL数据库 —— 文档型数据库



5.1 大数据概念

□ 大数据技术

➤ NoSQL数据库 —— 为什么需要NoSQL?

假设你是电商平台开发，需要存储“商品数据”。不同品类的商品，属性天差地别：

- 手机：品牌、型号、内存、摄像头像素、电池容量；
- 衣服：品牌、尺码、颜色、面料、是否加绒；
- 书籍：作者、ISBN、出版社、页数、装帧方式。

如果用关系型数据库，可以怎么做？

5.1 大数据概念

□ 大数据技术

➤ NoSQL数据库 —— 为什么需要NoSQL?

关系型数据库解决方案

□ 方案 1：建 1 张 “大商品表”，包含所有可能的字段

表结构：商品ID、名称、价格、品牌、型号、内存、摄像头、尺码、颜色、作者、ISBN.....

□ 方案 2：建 “主表 + 子表”，按品类拆分

主表：商品ID、名称、价格、品类（存储所有商品的公共属性）；

子表：手机表（商品ID、内存、摄像头...）、衣服表（商品ID、尺码、颜色...）、书籍表（商品ID、作者、ISBN...）；

5.1 大数据概念

□ 大数据技术

➤ NoSQL数据库 —— 为什么需要NoSQL?

文档数据库解决方案

```
// 手机文档
{
  "商品ID": "1001",
  "名称": "XX手机Pro",
  "价格": 4999,
  "品牌": "XX",
  "内存": "12GB",
  "摄像头": "5000万像素"
}
```

```
// 衣服文档
{
  "商品ID": "2001",
  "名称": "加绒卫衣",
  "价格": 199,
  "品牌": "YY",
  "尺码": ["S", "M", "L"],
  "颜色": "黑色",
  "面料": "棉80%"
}
```


时间换空间?

5.1 大数据概念

□ 大数据技术

➤ NoSQL数据库 —— 为什么需要NoSQL?

文档数据库+索引 -> 搜索(锁定犯罪嫌疑人)



全城50万人
档案数据库

5.1 大数据概念

□ 大数据技术

➤ NoSQL数据库 —— 为什么需要NoSQL?

倒排索引技术 —— 快速圈定

短语	出现短语的档案编号
张三	档案11、档案23、...
...	...
城东小区	档案9、档案11、...
城南菜市场	档案1、档案9、...
...	...
盗窃	档案2、档案9、...
...	...

5.1 大数据概念

□ 大数据技术

➤ NoSQL数据库 —— 为什么需要NoSQL?

BM25算法 —— 精准排序

- 关键词（线索）在文档（个人档案）出现的次数；
- 文档的长度：短文档里的关键词更有分量；
- 关键词的独特性：越少见的词越能说明问题

排序	档案编号	分数
1	档案11	95
2	档案32	89
3	档案31	88
...	...	...

5.1 大数据概念

□ 大数据技术

➤ 云数据库

云数据库是指被优化或部署到一个虚拟计算环境中的数据库,是在云计算的大背景下发展起来的一种新兴的共享基础架构的方法,它极大地增强了数据库的存储能力,消除了人员、硬件、软件的重复配置,让软,硬件升级变得更加容易。

云数据库具有高可扩展性、高可用性、采用多组形式和支持资源有效分发等特点,可以实现按需付费和按需扩展。

5.1 大数据概念

□ 大数据技术

数据清洗

在大数据时代,数据清洗通常是指把“脏数据”彻底洗掉。所谓“脏数据”,是指不完整、不规范、不准确的数据,只有通过数据清洗才能从根本上提高数据质量。

数据清洗包含两个重要的概念:原始数据和干净数据。

- 原始数据是来自数据源的数据,一般作为数据清洗的输入数据。由于原始数据的来源纷杂,因此不适合直接进行分析。
- 干净数据也称为目标数据,即符合数据仓库或上层应用逻辑规格的数据,也是数据清洗过程的结果数据。

5.1 大数据概念

□ 大数据技术

数据计算


面向大数据处理的数据查询、统计、分析、挖掘等需求,产生了大数据计算的不同计算模式,整体上人们把大数据计算分为离线批处理计算、实时交互计算和流计算3种。

- 离线批处理：批量处理大型数据集，但速度可能较慢。读取和写入数据需要访问外部存储，适合具有可容忍时间延迟的工作负载。
- 实时交互计算：旨在实时处理大量数据。在处理数据之前将其复制到内存，在完成特定任务后才将数据写回外部存储。
- 流计算：处理的是实时的持续数据流，也被称为无界数据集，即能够持续增长的、不可预测的无限数据集。

5.1 大数据概念

□ 大数据技术


数据计算-离线批处理 (MapReduce)



5.1 大数据概念


□ 大数据技术

数据计算-离线批处理(MapReduce)



5.1 大数据概念

□ 大数据技术



5.1 大数据概念

□ 大数据技术

数据分析与挖掘

数据分析是指用适当的统计分析方法对收集来的大量数据进行分析,为提取有用信息和形成结论而对数据加以详细研究和概括总结的过程。


数据挖掘是指通过大量数据集进行分类的自动化过程,通过数据分析识别趋势和模式,建立关系,解决业务问题。

5.1 大数据概念

□ 大数据技术

数据挖掘

数据挖掘是指通过大量数据集进行分类的自动化过程,通过数据分析识别趋势和模式,建立关系,解决业务问题。




5.1 大数据概念

□ 大数据技术

数据可视化

数据可视化越来越普及,在工业物联网、电信、智慧医疗、智能交通、现代农业等多个行业都有广泛的应用。



5.1 大数据概念


大数据技术



人数TOP10专业分布

- 行政管理(二学历)
- 治安学
- 法学(专升本)
- 侦查学
- 公安管理学
- 治安学(专升本)
- 经济犯罪侦查
- 刑事科学技术
- 网络安全与执法
- 公安管理学(二学历)


各年级人数分布情况



● 男生 ● 女生

年份	男生	女生
2017	685	118
2018	782	131
2019	1945	538
2020	1240	355
2021	1193	319
2022	1168	323
2023	1266	228
2024	1410	250

政治面貌分布情况



中国共产党党员 4906人

中国共产党预备党员 0.52%

群众 1293人

中国共产主义青年团员 5人

中国共产主义青年团团员 32人

5.1 大数据概念

□ 大数据技术



5.1 大数据概念

□ 大数据技术



5.1 大数据概念

□ 大数据技术

数据治理


数据治理是指从使用零散数据转变为使用统一数据、从具有很少或没有组织流程到企业范围内的综合数据管控、从数据混乱状况到数据井井有条的一个过程。

- 定义数据资产的具体职责和决策权,应用角色分配决策需要执行的确切任务的决策和规范活动。
- 为数据管理实践制定企业范围的原则、标准、规则和策略。
- 建立必要的流程,以提供对数据的连续监视和控制实践,并帮助在不同组织职能部门之间执行与数据相关的决策,以及业务用户类别。

5.2 工业大数据及其应用

□ 工业大数据概述

工业大数据即难以通过传统的分析工具进行有效分析的工业数据的集合,具备明显的大数据的**容量大、数据类型多、数据价值高、数据更新快**的特性。




5.2 工业大数据及其应用

□ 工业大数据概述

工业大数据与大数据的关系

工业大数据应用是**基于工业数据**,运用**先进的大数据相关思维、工具、方法**,贯穿于工业的设计、工艺、生产、管理、服务等各个环节,使工业系统、工业产品具备描述、诊断、预测、决策、控制等智能化功能模式和结果。

工业制造过程中需要高质量的工业大数据,可以借鉴大数据的治理机制对工业数据资产进行有效治理。




使用大数据技术对工业生产进行优化

5.2 工业大数据及其应用

□ 工业大数据概述

工业大数据与智能制造

工业大数据是智能制造的关键技术,主要作用是打通物理世界和信息世界,推动生产型制造向服务型制造转型。



工业大数据在智能制造中的应用

5.2 工业大数据及其应用

□ 工业大数据概述


工业大数据与工业互联网

以**数据**为核心构建的智能化体系会成为支撑智能制造和工业互联网的核心动力。

- 基于**数字孪生**的智慧研发场景应用
- 基于**柔性生产**的大规模个性化定制场景
- 基于产品**全生命周期管理**的设备预测管理

工业大数据参考架构

以工业过程的**业务需求为导向**,基于工业系统的业务架构,规划工业大数据的数据、技术和应用(平台)架构,搭建面向多业务领域、贯通多组织和应用层次的工业大数据 IT 架构。



5.2 工业大数据及其应用

□ 工业大数据的应用

预防性维修

预防性维修主要依赖于数据和建模,主要有两种思路。

- 一种基于机理辨别,对未知对象建立参数估计,进行阶次判定、时域分析、频域分析,或者建立多变量系统,进行线性和非线性、随机或稳定的系统分析等,试图揭示系统的内在规律和运行机理。
- 另一种则是基于人工智能相关的灰度建模思路,利用专家系统、决策树、基于主元分析的聚类算法、支持向量机(Support Vector Machine, SVM)和深度学习等深度学习相关方法,对数据进行分析 and 预测。

5.2 工业大数据及其应用

□ 工业大数据的应用

生产过程优化

基于大数据的生产过程优化,在制造过程数字化监控的基础上,用大数据、人工智能算法建立模型,研究不同参数变化对设备状态与整体生产过程的影响,并根据实时数据与现场工况动态调优,提供智能设备故障预警、工艺参数优推荐、降低能耗、提升良品率、提高工作效率等一项或多项功能。



5.2 工业大数据及其应用

□ 工业大数据的应用

智慧供应链

“智慧供应链”是结合物联网技术和现代供应链管理的理论、方法和技术，在企业中和企业间构建的实现供应链的智能化、网络化和自动化的技术与管理综合集成系统。

智慧供应链技术渗透性更强



供应链主动将管理过程适应引入新技术带来的变化。

可视化、移动化特征更明显



智慧供应链更倾向于使用可视化的手段表现数据，采用移动化的手段访问数据。

智慧供应链更人性化



智慧供应链更加系统地考虑问题，考虑人机系统的协调性，实现人性化的技术和管理系统。

5.2 工业大数据及其应用

□ 工业大数据的应用

智慧营销

智慧营销是大数据、物联网等信息技术与当代品牌营销领域新思维、新理念、新方法新工具以及人的创造性、创造力、创意智慧融合的产物。

工业污染与环保监测



工业大数据对环保具有巨大价值。大数据技术的植入,可明显增加环保数据解析的维度,透视众多企业的环境治理状况,开发出多种打击环保违法行为的手段,增强环境监管的效力。

5.3 工业大数据处理过程

工业大数据采集

工业大数据在线采集

在线数据是通过数据采集终端直接采集到的数据,如适配器对接设备控制器后直接采集到的数据。



工业大数据的现场数据采集


5.3 工业大数据处理过程

□ 工业大数据采集

工业大数据离线采集

离线数据是相对于在线数据而言的，离线数据就是不能通过数据采集终端直接采集的数据。

在大数据离线采集中，特别是在互联网应用中，不管是采用哪一种采集方式，其基本的数据来源大都是日志数据。



5.3 工业大数据处理过程

□ 工业大数据采集

工业大数据

Date_Time	Product_Type	Duty_Cycle	Pulse_Width(us)	Frequency(Hz)	DC_Voltage	Quiescent Current(mA)	Power(mW)	I2C_Success?	EEPROM_Written?
2015/2/6 10:21	CN9401	50%	10	1000	3.339	13.825889	46.164643	1	1
2015/2/6 10:21	CN9401	50%	10	1000	3.394	14.741810	50.033703	1	1
2015/2/6 10:23	CN9401	50%	10	1000	3.333	13.093472	43.640542	1	1
2015/2/6 10:30	CN9401	50%	10	1000	3.327	13.646202	45.400914	0	0
2015/2/6 10:34	CN9401	50%	10	1000	3.359	12.256747	41.170413	1	1
2015/2/6 10:35	CN9401	50%	10	1000	3.380	11.722519	39.622114	1	1
2015/2/6 10:36	CN9401	50%	10	1000	3.392	12.712670	43.121377	1	1
2015/2/6 10:37	CN9401	50%	10	1000	3.322	11.351435	37.709467	1	1
2015/2/6 10:38	CN9401	50%	10	1000	3.375	11.421032	38.545983	1	1
2015/2/6 10:39	CN9401	50%	10	1000	3.338	11.223186	37.462995	1	1
2015/2/6 10:40	CN9401	50%	10	1000	3.337	11.015128	36.757482	1	1
2015/2/6 10:42	CN9401	50%	10	1000	3.357	12.613403	42.343194	1	1
2015/2/6 10:50	CN9401	52%	11	1010	3.373	13.497467	45.526956	1	1
2015/2/6 10:51	CN9401	50%	10	1000	3.337	14.614825	48.769671	1	1
2015/2/6 10:52	CN9401	50%	10	1000	3.395	13.007501	44.160466	1	1
2015/2/6 10:53	CN9401	50%	10	1000	3.362	12.744772	42.847923	1	1
2015/2/6 10:54	CN9401	50%	10	1000	3.342	12.808742	42.806816	1	1
2015/2/6 10:55	CN9401	50%	10	1000	3.389	12.596628	42.689972	1	1
2015/2/6 10:56	CN9401	50%	10	1000	3.378	13.745854	46.433495	1	1
2015/2/6 10:57	CN9401	50%	10	1000	3.315	13.290837	44.059125	1	1
2015/2/6 10:58	CN9401	50%	10	1000	3.346	12.380036	41.423600	1	1
2015/2/6 10:59	CN9401	50%	10	1000	3.337	13.401496	44.720792	1	1
2015/2/6 11:00	CN9401	50%	10	1000	3.311	12.695741	42.035598	1	1
2015/2/6 11:40	CN9401	50%	10	1000	3.377	14.006074	47.298512	1	1
2015/2/6 11:42	CN9401	50%	10	1000	3.391	13.729102	46.555385	1	1
2015/2/6 11:43	CN9401	50%	10	1000	3.348	14.301002	47.879755	1	1

- 带有时间戳
- 结构化数据
- 数据量大

5.3 工业大数据处理过程

□ 工业大数据预处理

数据异常处理

异常值也叫作离群值,通常是指采集数据时可能因为技术或物理原因,数据取值超过数据值域范围。

异常值通常分为两种:

- 伪异常是由于特定的业务运营动作产生,是正常反映业务的状态,而不是数据本身的异常;
- 真异常不是由于特定的业务运营动作产生,而是数据本身分布异常,即离群值。

5.3 工业大数据处理过程


□ 工业大数据预处理

数据缺失处理

在数据集中,若某记录的属性值被标记为空白或“-”等,则认为该记录存在缺失值(空值),也常指不完整的数据。造成数据缺失的原因:

造成数据缺失的原因:如空值条件的设置、业务数据的脱密、异常数据的删除等,都会造成一定程度的数据缺失。


处理缺失值可以按照以下4个步骤进行



5.3 工业大数据处理过程

□ 工业大数据建模

DIKW模型




5.3 工业大数据处理过程

□ 工业大数据建模

知识工程



工业领域的知识按照其属性可以分为



5.3 工业大数据处理过程

□ 工业大数据建模

工业建模基础

数据建模的本质是根据一部分能够获得的数据**获得另一部分不统一直接获得的数据**。



由于应用场景的不同以及数据采集条件的不断变化,模型的误差可能会变得很大,对建模过程产生深刻的影响。

复杂模型建立

对于工业数据建模中部分数据无法获得的问题,一般的解决方法是从可以获得的数据中找到一些与之相关的数据,再用间接的手段确定模型。


工业大数据模型理解

工业大数据的根本优势是数据的质量好质量好的一个方面就是数据分布范围大,覆盖了各种可能发生的情况。

5.3 工业大数据处理过程

□ 工业大数据建模

工业大数据的参考模型 CRISP-DM



CRISP-DM模型

5.3 工业大数据处理过程

□ 工业大数据建模

工业大数据建模应用




5.3 工业大数据处理过程

□ 工业大数据分析

认识工业大数据分析

工业大数据分析是利用统计学分析技术、机器学习技术、信号处理技术等技术手段,结合业务知识对工业过程中产生的数据进行处理、计算、分析并提取其中有价值的信息、规律的过程。



5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的类型

工业大数据分析常见的类型可分为描述类、诊断类、预测类、决策类和控制类等。

01

描述类

利用报表、可视化等技术,汇总展现工业互联网各个子系统的状态。

02

诊断类

采集工业生产过程相关的数据评估工业系统运行状态并预测其未来健康状况。

03

预测类

预测类通过对系统历史数据的分析挖掘,预测系统的未来行为。

04

决策类

分析与挖掘影响决策的数据,发现决策相关的结构与规律。

05

控制类


通过数据分析产生行动指令,控制生产系统采取行动。

5.3 工业大数据处理过程

□ 工业大数据分析

机器学习

机器学习是一门涉及多领域的交叉学科,其包含高等数学、统计学、概率论、凸分析和逼近论等多门学科。



5.3 工业大数据处理过程

□ 工业大数据分析

机器学习

工业大数据建模任务一般可以分为无监督学习和监督学习。

- 无监督学习是从无标注的数据中学习数据的统计规律或者说内在结构的机器学习，主要包括聚类、降维、概率估计；
- 监督学习主要建立输入与输出之间的函数映射，包括回归和分类，因此输出的预测精度是一个关键的因素。



5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的常见算法

➤ 聚类分析

聚类分析是指对一批没有标出类别的样本(可以看作数据框中的一行数据)按照样本之间的相似度进行分类,将相似的归为一类,不相似的归为另一类的过程。

相似度(距离)

Lp距离 (闵式距离)

$$L_p(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^p \right)^{\frac{1}{p}}$$

5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的常见算法

➤ 聚类分析（无监督）

当 $p=1$ 时，曼哈顿距离（绝对值距离）：

$$L_1(x_i, x_j) = \sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|$$



当 $p=2$ 时，欧式距离：

$$L_2(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^2 \right)^{\frac{1}{2}}$$

当 $p=\infty$ 时，切贝雪夫距离：

$$L_\infty(x_i, x_j) = \max_l |x_i^{(l)} - x_j^{(l)}|$$

$$L_p(x_i, x_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^p \right)^{\frac{1}{p}}$$



5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的常见算法

➤ 聚类分析(无监督)—— K-means 聚类

输入: n 个样本的集合 X ;

输出: 样本集合的聚类 C^* 。

(1) 初始化。令 $t = 0$, 随机选择 k 个样本点作为初始聚类中心 $m^{(0)} = (m_1^{(0)}, \dots, m_l^{(0)}, \dots, m_k^{(0)})$ 。

(2) 对样本进行聚类。对固定的类中心 $m^{(t)} = (m_1^{(t)}, \dots, m_l^{(t)}, \dots, m_k^{(t)})$, 其中 $m_l^{(t)}$ 为类 G_l 的中心, 计算每个样本到类中心的距离, 将每个样本指派到与其最近的中心的类中, 构成聚类结果 $C^{(t)}$ 。

(3) 计算新的类中心。对聚类结果 $C^{(t)}$, 计算当前各个类中的样本的均值, 作为新的类中心 $m^{(t+1)} = (m_1^{(t+1)}, \dots, m_l^{(t+1)}, \dots, m_k^{(t+1)})$ 。

(4) 如果迭代收敛或符合停止条件, 输出 $C^* = C^{(t)}$ 。

否则, 令 $t = t + 1$, 返回步 (2)。




5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的常见算法

➤ 聚类分析(无监督)—— K-means 聚类



5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的常见算法

➤ 降维分析

将关系紧密的变量转换为尽可能少的新变量,使这些新变量两两不相关,那么就可以用较少的综合指标分别代表存在于各个变量中的各类信息。

数据降维的优点

- (1) 解决“维数灾难”,缓解“信息丰富、知识贫乏”的现状,降低复杂度;
- (2) 更好地认识和理解数据。


5.3 工业大数据处理过程

□ 工业大数据分析



工业大数据分析的常见算法

➤ 降维分析（无监督）

常用的降维算法有主成分分析和因子分析



数据集在**三维**特征空间中的分布




数据集在**二维**特征空间中的分布

5.3 工业大数据处理过程

工业大数据分析

工业大数据分析的常见算法


- 主成分分析直观理解（从方差的角度）
- 数据从二维数据降低到一维数据，来可视化，那什么样的降维是好的？**数据尽可能在一维上分散开**
- 主成分分析PCA选择方差最大的方向（第一主成分）作为新坐标系的第一坐标轴，即 y_1 轴，在这里意味着选择椭圆的长轴作为新坐标系的第一坐标轴；之后选择与第一坐标轴正交，且方差次之的方向（第二主成分）作为新坐标系的第二坐标轴，即 y_2 轴
- 将数据投影到 y_1 轴上，让数据尽可能分散开。



5.3 工业大数据处理过程

□ 工业大数据分析

主成分分析可视化，让降维后的数据尽可能分散开



5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的常见算法


➤ SVM (监督)

支持向量机(Support Vector Machine, SVM)是一种支持线性分类和非线性分类的二元分类算法,经过演进现在也支持多元分类,目前被广泛地应用在回归以及分类当中。

支持向量机的原理为对样本数据进行分类,实际是对决策函数进行求解。

支持向量机的步骤:

- (1) 找到分类问题中的最大分类间隔,
- (2) 确定最优分类超平面,并将分类问题转化为二次规划问题进行求解。



5.3 工业大数据处理过程


□ 工业大数据分析

工业大数据分析的常见算法

➤ 决策树算法

决策树是应用最广的归纳推理算法之一,它是一种逼近离散值函数的方法,对噪声数据有很好的健壮性且能够学习析取表达式。

决策树通过把实例从根节点排列(Sort)到某个叶子节点来分类实例,叶子节点即为实例所属的分类。




5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的常见算法

- 决策树算法核心：每次决策尽可能获得最大的信息增益（尽可能缩小范围，降低不确定性）；
- 微软小冰 15个问题 猜人名游戏



5.3 工业大数据处理过程

□ 工业大数据分析


工业大数据分析的常见算法

➤ 关联规则算法

关联规则是反映一个事物与其他事物之间的相互依存性和关联性,是数据挖掘的一个重要技术,用于从大量数据中挖掘出有价值的项之间的相关关系。

关联规则挖掘的过程主要包含:


(1) 从数据集中找到所有频繁项集, (2) 产生强关联规则。



5.3 工业大数据处理过程

□ 工业大数据分析

➤ Apriori算法



$$2^N - 1$$


5.3 工业大数据处理过程

□ 工业大数据分析

Apriori算法

- 最著名的数据挖掘算法之一;
- 核心思想:
 - 如果一个集合是频繁的, 那它的所有子集也一定是频繁的;
 - 如果一个集合是不频繁的, 那包含它的所有超集也一定是不频繁的。
- 算法:
 1. 生成大小为size的候选集合(size=1);
 2. 扫描数据库, 判断哪些候选集合是频繁的;
 3. 使用频繁的集合, 构造新的候选集合 (size=size+1)

订单编号	购买的商品
1	牛奶、面包、尿布
2	可乐、面包、尿布、啤酒
3	牛奶、尿布、啤酒、鸡蛋
4	面包、牛奶、尿布、啤酒



5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的常见算法

➤ 贝叶斯算法

贝叶斯算法是统计模型决策中的一个基本方法,其基本思想是已知条件概率密度参数表达式和先验概率,利用贝叶斯公式转换为后验概率,再根据后验概率大小进行决策分类。

朴素贝叶斯算法是最常用的一种贝叶斯算法,它是基于贝叶斯公式建立的,朴素贝叶斯算法计算式为

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}$$

朴素贝叶斯算法主要用于分类问题,如新闻分类、文本分类、病人分类、邮件分类等。

5.3 工业大数据处理过程

□ 工业大数据分析

工业大数据分析的常见算法

➤ 贝叶斯算法 —— 判断垃圾邮件

经过统计：



- 垃圾邮件中，带链接的比例是0.6，不带链接比例是0.4；
- 正常邮件中，带链接的比例是0.2，不带链接的比例是0.8；

问：现在一封新的邮件，带了链接，它是垃圾邮件的概率是多少？

5.3 工业大数据处理过程

工业大数据可视化

三维可视化的应用



云计算服务监控大屏



5.4 工业大治理

□ 工业大数据治理概述

认识工业大数据治理

数据治理是指从使用零散数据变为使用统一数据、从具有很少或没有组织流程到企业范围内的综合数据管控、从数据混乱状况到数据井井有条的一个过程。



如何在企业内部用统一视角看待数据,让数据在企业中存好用好,发挥出更大价值,是企业数字化转型必然面临的问题。

数据治理正是解决这一问题的利器。

过去数据治理往往在**高价值数据集中且规范程度较高的企业(如金融业)**受到重视,但现在更多的企业(包括互联网)也**重视数据治理**的建设。

5.4 工业大治理

□ 工业大数据治理概述

工业大数据治理的主要环节

数据治理是专注于将数据作为企业的商业资产进行应用和管理的一套管理机制，它能够消除数据的不一致性，建立规范的数据应用标准，提高组织的数据质量，实现数据广泛共享。




数据治理不仅需要完善的保障机制,还需要理解具体的治理内容。

5.4 工业大治理

□ 工业大数据治理核心内容

主数据与元数据管理

主数据通常需要在整个企业范围内保持一致性(Consistent)、完整性(Complete)、可控性(Controlled),为了达成这一目标,就需要进行主数据管理(Master Data Management, MDM)。




5.4 工业大治理

□ 工业大数据治理核心内容

主数据与元数据管理

为了更好地管理主数据,企业常常需要建设主数据管理平台,该平台从功能上主要包括




5.4 工业大治理

□ 工业大数据治理核心内容

主数据与元数据管理

元数据是描述企业数据的相关数据(包括对数据的业务、结构、定义、存储、安全等各方面对数据的描述),一般是指在 IT 系统建设过程中所产生的有关数据定义、目标定义、转换规则等相关的关键数据,在数据治理中具有重要的地位。



5.4 工业大治理

□ 工业大数据治理核心内容

数据质量与数据管理

➤ ISO 8000数据质量标准

ISO 8000数据质量标准是针对数据质量制定的国际标准化组织标准，标准致力于管理数据质量，具体来说，包括规范和管理数据质量活动、数据质量原则、数据质量术语、数据质量特征（标准）和数据质量测试。


5.4 工业大治理

□ 工业大数据治理核心内容

数据质量与数据管理

➤ 数据质量标准

数据价值的成功发掘必须依托于高质量的数据，唯有准确、完整、一致的数据才有使用价值。




5.4 工业大治理

□ 工业大数据治理核心内容

数据质量与数据管理

➤ 数据周期管理

数据生命周期从数据规划开始,中间是一个包括设计、创建、处理、部署、应用、监控、存档、销毁这几个阶段并不断循环的过程。



在数据全周期管理中,最重要的几方面为数据规划、数据设计、数据创建和数据使用。

5.4 工业大治理

□ 工业大数据治理核心内容

数据标准

数据标准是指对数据的表达、格式及定义的一致约定,包括数据业务属性、技术属性和管理属性的统一定义。

➤ 数据标准分类

数据标准通常可分为基础类数据标准和指标类数据标准。

➤ 数据标准管理

- (1) 理解数据标准化需求。
- (2) 构建数据标准体系和规范
- (3) 规划制定数据标准化的实施路线和方案
- (4) 制定数据标准管理办法和实施流程要求
- (5) 建设数据标准管理工具,推动数据标准的执行落地。
- (6) 评估数据标准化工作的开展情况。

5.4 工业大治理

□ 工业大数据治理核心内容

数据治理框架

01

国际标准化组织 ISO 38500 治理框架

认为IT治理的目标就是促进组织高效、合理地利用 IT。

02

国际数据管理协会数据治理框架

数据治理是对数据资产管理行使权力和控制，包括规划、监控和执行。

03

国际数据治理研究所数据治理框架

认为数据治理不同于 IT 治理,应建立独立的数据治理理论体系。

04

IBM 数据治理框架

IBM最先提出数据治理概念的公司,提出了数据治理统一流程理论。

05

DCMM 数据治理框架

数据管理能力成熟度评估模型是我国首个数据管理领域国家标准。

06

ISACA 数据治理框架

目前国际上公认的最先进、最权威的信息技术管理和控制的标准。

总结

- 大数据的特点：数据量大、类型多、产生速度快、价值密度低；
 - 大数据存储困难：分布式、NoSql、云数据库；
 - 大数据处理困难：数据清洗、批处理、流式计算、交互式计算；
 - 大数据分析困难：可视化、数据挖掘；
 - 大数据风险：数据治理；
-
- 工业大数据与大数据、智能制造和工业互联网关系；
 - 工业大数据的应用；
 - 工业大数据处理过程；
 - 工业大数据治理；